

# XLIX PROGRAMA DE VERÃO (2020)

## Introdução ao Aprendizado por Reforço

### Preliminares

Fevereiro 2020

Esse material delinea os principais princípios matemáticos e estatísticos para um bom acompanhamento do curso. Para os alunos que não estejam familiarizados com algum dos tópicos: não se preocupem; procurem pelos links e referências em cada seção para materiais externos que os ajudarão com o conteúdo.

Uma boa leitura e nos vemos semana que vem!

## 1 Vetores e Matrizes

O curso assume que o aluno está familiarizado com o básico de vetores e operações sobre vetores. Seja  $\mathbf{x}$  um vetor  $n$ -dimensional com componentes

$$\mathbf{x} = (x_1, x_2, \dots, x_n).$$

Então  $\|\mathbf{x}\|$  denota o comprimento, ou norma, desse vetor, normalmente usando a definição Euclidiana:

$$\|\mathbf{x}\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

O produto interno  $\mathbf{w} \cdot \mathbf{x}$  é definido como:

$$\mathbf{w} \cdot \mathbf{x} = \sum_{i=1}^n w_i x_i$$

e tem uma interpretação natural como:

$$\mathbf{w} \cdot \mathbf{x} = \|\mathbf{w}\| \|\mathbf{x}\| \cos \theta$$

onde  $\theta$  é o ângulo entre os dois vetores. Logo, se as normas dos dois vetores são fixadas, então seu produto interno é maior quando  $\theta = 0$ , ou seja, quando um é múltiplo de outro.

Matrizes são denotadas por letras maiúsculas como  $A$ . Se o elemento da  $i$ -ésima linha e  $j$ -ésima coluna é  $A_{ij}$ , então  $A^T$  denota a matriz que tem  $a_{ji}$  no seu lugar - a *transposta* de  $A$ . Por exemplo, se  $A$  é uma matriz  $3 \times 3$ :

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{pmatrix}$$

então sua transposta é:

$$A^T = \begin{pmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{pmatrix}$$

O produto de duas matrizes  $A$  e  $B$  tem  $\sum_k A_{ik} B_{kj}$  na  $i$ -ésima linha e  $j$ -ésima coluna. A matriz  $I$  é a *identidade* ou matriz unitária, necessariamente quadrada, com 1s na diagonal e 0s em todo o resto. Para informações sobre vetores e matrizes, veja os vídeos introdutórios do [Linear Algebra Review](#) do Machine Learning by Stanford no Coursera.

## 2 Probabilidade básica e distribuições

Neste curso, representaremos **distribuições de probabilidade** sobre um conjunto  $\mathcal{X}$  usando funções da seguinte maneira. Se  $\mathcal{X}$  é um conjunto discreto (de cardinalidade finita ou infinita enumerável), então por distribuição de probabilidade em  $\mathcal{X}$  queremos dizer uma função  $p : \mathcal{X} \rightarrow \mathbb{R}$  que satisfaz:

$$p(x) \geq 0 \ (\forall x \in \mathcal{X}) \quad \text{e} \quad \sum_{x \in \mathcal{X}} p(x) = 1 .$$

Se  $\mathcal{X} \subseteq \mathbb{R}^n$ , então queremos dizer uma função  $p : \mathcal{X} \rightarrow \mathbb{R}$  tal que:

$$p(x) \geq 0 \ (\forall x \in \mathcal{X}) \quad \text{e} \quad \int p(x) dx = 1 .$$

Em outras palavras,  $p$  é a função densidade de probabilidade em  $\mathcal{X}$ . Aqui o domínio de integração é o conjunto  $\mathcal{X}$  inteiro. Quando  $n \geq 2$ ,  $\int$  denota uma integral múltipla.

Escrevemos  $x \sim p$  quando a variável  $x$  é amostrada de  $\mathcal{X}$  de acordo com a distribuição  $p$ . Seja  $f : \mathcal{X} \rightarrow \mathbb{R}$  um função qualquer de  $x$ . Definimos então o valor esperado de  $f(x)$  no caso discreto como

$$\mathbb{E}_{x \sim p} [f(x)] = \sum_{x \in \mathcal{X}} f(x)p(x) .$$

No caso contínuo, o valor esperado de  $f(x)$  é dado por

$$\mathbb{E}_{x \sim p} [f(x)] = \int f(x)p(x)dx .$$

Para uma visão geral sobre distribuições de probabilidade, confira o artigo na [Wikipedia](#).

## 3 Derivadas e gradientes




Figura 1: Tangente de uma função. A inclinação da reta tangente é equivalente à derivada da função naquele ponto. Fonte: [en.wikipedia.org](#)

Seja  $f : \mathbb{R} \rightarrow \mathbb{R}$  uma função univariada. Sua derivada é definida como

$$f'(x) = \lim_{\epsilon \rightarrow 0} \frac{f(x + \epsilon) - f(x)}{\epsilon} ,$$

e pode ser interpretado como a inclinação da reta tangente a  $f$  em  $x$ .

Neste curso, lidaremos com funções de várias variáveis com frequência. Seja  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  uma função de  $n$  variáveis. A derivada parcial de  $f(\mathbf{x})$  com relação a  $x_i$  é dada por

$$\frac{\partial f}{\partial x_i}(\mathbf{x}) = \lim_{\epsilon \rightarrow 0} \frac{f(x_1, \dots, x_i + \epsilon, \dots, x_n) - f(x_1, \dots, x_n)}{\epsilon} .$$




Figura 2: Vetores gradiente em vários pontos da função  $f(x_0, x_1) = \cos(x_0) \sin(x_1)$  (fonte: [citadel.sjfc.edu](http://citadel.sjfc.edu)).

O *gradiente* de  $f(\mathbf{x})$  é o vetor de derivadas parciais de  $f$  em  $\mathbf{x}$ :

$$\nabla f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(\mathbf{x}) \\ \frac{\partial f}{\partial x_2}(\mathbf{x}) \\ \vdots \\ \frac{\partial f}{\partial x_n}(\mathbf{x}) \end{bmatrix}$$

e pode ser interpretado como a direção de crescimento máximo de  $f$ , localmente em  $\mathbf{x}$ . Para mais informações sobre gradientes, confira o material na [Wikipedia](https://pt.wikipedia.org/wiki/Gradiente).